

一、选择题（每小题 3 分,共 30 分）：

1、使用哪个库可以方便地进行数据的可视化？（ ）

A. NumPy

B. Pandas

C. Matplotlib

D. Scikit-learn

2、考虑下面的 3×4 矩阵 $A = \text{np.array}([[1,2,3,4], [5,6,7,8], [9,10,11,12]])$, 表达式 $A[2, :]$ 的结果是 ().

A. $\text{array}([[1, 2, 3, 4],$
 $[5, 6, 7, 8]])$

B. $\text{array}([9, 10, 11, 12])$

C. $\text{array}([3, 7, 11])$

D. $\text{array}([5,6,7,8])$

3、可以利用 numpy 库中的函数 array, arange, empty, linspace 等函数生成数组, 以下能生成数组 $\text{array}([-1. , -0.25, 0.5 , 1.25, 2.])$ 的函数示例是 ().

A. $\text{np.arange}(4, \text{dtype}=\text{float})$ B. $\text{np.arange}(0,10,2, \text{dtype}=\text{int})$

C. $\text{np.empty}((2,3), \text{int})$ D. $\text{np.linspace}(-1,2,5)$

4、运算结果 `np.arange(1,10).reshape(3,3).T.dot(np.eye(3)) = (      )`.

A. `array([[1, 2, 3], [4, 5, 6], [7, 8, 9]])`

B. `array([[1, 4, 7], [2, 5, 8], [3, 6, 9]])`

C. `array([[1, 0, 0], [0, 1, 0], [0, 0, 1]])`

D. `array([[3, 6, 9], [2, 5, 8], [1, 4, 7]])`

5、使用 Pandas 的 `describe()`方法时，默认会计算哪些统计量？ ()

A. 均值、中位数、众数

B. 均值、标准差、最小值、最大值、四分位数

C. 频数、累计频数、比例

D. 方差、协方差、相关系数

6、下面哪个 Pandas 函数可以用于读取 CSV 文件？ ()

A) `read.csv()`

B) `load_csv()`

C) `read_csv()`

D) `csv_read()`

7、设 A 是一矩阵，则函数 `np.linalg.eig(A)`的返回值是 ()

A. A 的特征值

B. A 的特征值

C. A 的特征值和特征向量

D. 无返回值

8、NumPy 主要用于什么？ ()

A. 数据可视化

B. 机器学习

C. 数值计算

D. 数据清洗

9、如果你想通过 PCA(主成分分析)将数据集从高维降到二维以便可视化，你应该如何设置 `n_components` 参数？ ()

A. `n_components=2`

B. `n_components='mle'`

C. `n_components=None`

D. `n_components` 设置为原数据集的维度数

10、在做距离判别分类的时，可以使用 `sklearn.neighbors` 模块的 `KNeighborsClassifier` 函数来处理，若需要创建一个指定分类类别数为 2，距离选择为马氏距离的对象的代码为 ()

- A. KNeighborsClassifier(2, metric='euclidean')
- B. KNeighborsClassifier(2, metric='manhattan')
- C. KNeighborsClassifier(2, metric='minkowski')
- D. KNeighborsClassifier(2, metric='mahalanobis')

二、填空题（每小题 3 分，共 30 分）：

- 1、样本 $x_1, x_2, \dots, x_n$ 的平均数计算公式为: _____
- 2、设 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 为样本 $x_1, x_2, \dots, x_n$ 的次序统计量, 则该组样本的中位数的计算公式是 $M =$ _____
- 3、若 p 维总体 $\vec{X} = (X_1, X_2, \dots, X_p)^T$ 服从参数为 $N_p(\vec{\mu}, \Sigma)$ 的 p 维正态分布, 则其概率密度函数为 _____
- 4、两个维数为 p 的总体 $\vec{X}, \vec{Y}$ 协方差矩阵为 _____
- 5、设变量 $\vec{X} = (X_1, X_2)$ 的均值为 $\vec{0}$, $\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$. 令 $Y = X_1 + X_2$, 则 $\text{Var}(Y) =$ _____
- 6、对于线性回归模型 $\vec{Y} = X\vec{\beta} + \vec{\varepsilon}$, 设参数 $\vec{\beta}$ 的最小二乘估计为 $\hat{\vec{\beta}}$, 则 $E(\hat{\vec{\beta}}) =$ _____
- 7、设 $\vec{X} = (X_1, X_2, \dots, X_p)^T$ 的协方差矩阵为 $\Sigma = (\sigma_{ij})_{p \times p}$, $P = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_p)$ 为由 Σ 的 p 个正交单位化特征向量为列所构成的矩阵, $\vec{Y} = (Y_1, Y_2, \dots, Y_p)^T$ 为 $\vec{X}$ 的 p 个主成分所构成的向量, 则 $\vec{Y} =$ _____
- 8、设 $\vec{x}, \vec{y}$ 是来自均值向量为 $\vec{\mu}$, 协方差矩阵为 Σ 的总体 G 的两个样品, 则 $\vec{x}, \vec{y}$ 之间的欧式平方距离是 $d^2(\vec{x}, \vec{y}) =$ _____
- 9、已知 $\vec{X} = [x_1, x_2]^T$ 服从二维正态分布 $N(\vec{\mu}, \Sigma)$, 其中 $\vec{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\Sigma = \begin{bmatrix} 1 & 0.9 \\ 0.9 & 1 \end{bmatrix}$, 试求点 $\alpha = [1, 1]^T$ 到总体均值的马氏距离平方 _____
- 10、当一个判别准则提出以后, 还要研究它的优良性, 即考察它的误判率. 以训练样本为

基础的误判率的估计思想如下:若属于 G_1 的样品被误判为属于 G_2 的个数为 N_1 个, 属于 G_2 的样品被误判为属于 G_1 的个数为 N_2 个, 两类总体的样品总数为 N , 则误判率 P 的估计为 $\hat{P} =$ _____

三、设三维随机向量 $X \sim N_3(\mu, 2I_3)$, 已知

$$\mu = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix}, \quad A = \begin{bmatrix} 1 & -2 & 1 \\ -1 & 0 & -1 \end{bmatrix}, \quad d = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

试求 $Y = AX + d$ 的分布. (10 分)

四、设 $y_i = \beta_0 + \beta_1 x_i + \beta_2 (3x_i^2 - 2) + \varepsilon_i (i=1,2,3)$, $x_1 = -1, x_2 = 0, x_3 = 1$, 其中, $\varepsilon_1, \varepsilon_2, \varepsilon_3$ 相互独立, 服从 $N(0, \sigma^2)$ 正态分布.

(1) 写出矩阵 $Y = X\vec{\beta} + \vec{\varepsilon}$ 中的 X ; (4 分)

(2) $\vec{\beta} = (\beta_0, \beta_1, \beta_2)^T$ 的最小二乘估计. (6 分)

五、设随机向量 $\vec{X} = (X_1, X_2, X_3)^T$ 的协方差矩阵为

$$\Sigma = \begin{bmatrix} 1 & -2 \\ -2 & 5 \end{bmatrix},$$

求 $\vec{X}$ 的各主成分. (10 分)

六、设有 3 个组 G_1, G_2 和 G_3 ，欲判别某样品 x_0 属于何组，已知先验概率 $p_1 = 0.1, p_2 = 0.6, p_3 = 0.3$ ，且 $f_1(x_0) = 0.1, f_2(x_0) = 0.6, f_3(x_0) = 2$ 。求 x_0 属于各组的后验概率，并判别 x_0 应该属于哪一组。（10 分）